

Conteo de plantas de *Solanum tuberosum* utilizando Redes Neuronales Convolucionales

Juan Arbeláez, Javier Gómez, Gina Posada, Felipe Serrano
Departamento de Ingeniería de Sistemas y Computación,
Universidad de los Andes
Bogotá, Colombia

Resumen—Este estudio investiga la aplicación de Redes Neuronales Convolucionales YOLO v11, para el conteo automatizado de plantas de *Solanum tuberosum* (papa) utilizando imágenes capturadas por dron. La metodología incluyó un proceso sistemático de preprocesamiento de imágenes tomadas a una altitud de 100 metros, aumento de datos, entrenamiento y evaluación del modelo. El modelo entrenado con imágenes aumentadas alcanzó una mAP50-95 (*mean Average Precision*) de 0.18 %, superando el rendimiento del modelo base sin aumento de datos, que obtuvo una mAP50-95 de 0.11 %. El estudio concluye que el aumento de imágenes es una estrategia metodológica efectiva que permite extraer conocimientos más profundos de los conjuntos de datos de entrenamiento, mejorando la capacidad de generalización de modelos de detección como YOLO. Además, se destaca el potencial de estas tecnologías de aprendizaje automático para el conteo de cultivos de papa que podrían ser aplicados en el contexto de la agricultura colombiana proporcionando herramientas para mejorar los procesos productivos actuales.

Index Terms—Aprendizaje automático, redes neuronales, conteo cultivos, visión computacional, aumentación de datos.

I. INTRODUCCIÓN

EL monitoreo preciso de cultivos representa un desafío crítico en la agricultura moderna, particularmente en cultivos como la papa, donde el conteo de plantas es esencial para evaluar la densidad y el estado de salud del cultivo. Los métodos tradicionales, basados en procedimientos manuales, presentan limitaciones significativas, ya que son intensivos en mano de obra, propensos a errores humanos y poco prácticos para cubrir grandes extensiones de terreno de manera eficiente.

En los últimos años, el avance de tecnologías como los drones y las Redes Neuronales Convolucionales (CNNs) ha abierto nuevas posibilidades para superar estas limitaciones. En particular, algoritmos de aprendizaje automático como YOLO (*You Only Look Once*) han demostrado un potencial notable en la detección y el conteo automatizado de objetos en imágenes agrícolas, ofreciendo soluciones más rápidas, precisas y escalables.

Este estudio se centra en evaluar la eficacia de YOLO v11 para el conteo automatizado de plantas de papa utilizando imágenes aéreas capturadas por drones. Además, se pone especial énfasis en el uso de técnicas de aumentación de datos, una estrategia clave para mejorar la precisión del modelo en

escenarios donde la calidad y la cantidad de datos disponibles son factores determinantes.

II. OBJETIVOS

El presente proyecto tiene como objetivo principal desarrollar y validar una solución basada en CNNs para el conteo automatizado y preciso de plantas de papa utilizando imágenes aéreas capturadas por drones. Esta solución pretende optimizar la gestión de cultivos en Colombia al proporcionar datos precisos y confiables que respalden la toma de decisiones informada en el manejo agrícola.

Específicamente, se busca mejorar la eficiencia en la asignación de recursos clave, como fertilizantes, agua y mano de obra, al tiempo que se minimizan los costos operativos asociados con el uso de insumos innecesarios. Esto no solo incrementará la competitividad de los productores en el mercado, sino que también promoverá prácticas agrícolas más sostenibles y eficientes.

A nivel nacional, esta tecnología tiene el potencial de contribuir significativamente al control de inventarios de papa, fortaleciendo la seguridad alimentaria mediante una producción agrícola más efectiva y resiliente. Al garantizar una gestión más precisa y sostenible de los cultivos, el sistema propuesto sienta las bases para el desarrollo de modelos de agricultura inteligente en el país.

III. PLANTEAMIENTO DEL PROBLEMA

La inseguridad alimentaria en Colombia es un problema crítico que afecta a millones de hogares y pone en riesgo la estabilidad social y económica del país. Actualmente, de un total de 8,5 millones de hogares, solo el 72,4 % (6,15 millones) logra completar las tres comidas diarias, mientras que un significativo 26,5 % (2,2 millones) subsiste con solo dos comidas al día. Además, 92.857 familias (1,1 %) viven con una única comida diaria, e incluso 1.820 hogares no tienen la capacidad de suplir un solo plato al día [1]. En este contexto, la papa se posiciona como un alimento básico para la dieta de la población colombiana, desempeñando un papel fundamental en la seguridad alimentaria.

El cultivo de papa no solo es esencial para la seguridad alimentaria, sino también para la economía rural del país, ya que contribuye a los cuatro pilares de esta: disponibilidad, acceso, utilización y estabilidad [2]. Sin embargo, enfrenta serios desafíos, como la baja productividad y la limitada

implementación de tecnologías de monitoreo, especialmente en los minifundios que representan el 80 % de la producción nacional. Estas limitaciones agravan la situación del sector, que ya enfrenta un incremento considerable en los costos de producción. Por ejemplo, el costo promedio de cultivar una hectárea de papa se ha duplicado en los últimos dos años, pasando de 22 millones de pesos a casi 40 millones, siendo los insumos agrícolas el principal factor de este aumento, representando aproximadamente el 56 % del total [3].

A pesar de su importancia, los métodos actuales para el conteo de plantas en los cultivos de papa siguen siendo manuales, lo que los hace propensos a errores, poco eficientes y costosos en términos de tiempo y mano de obra. La falta de precisión en este proceso limita la optimización agronómica, reduce los rendimientos y eleva los costos operativos, afectando directamente la competitividad de los productores, particularmente los pequeños y medianos agricultores.

Ante este panorama, este proyecto desarrolla una solución innovadora basada en CNNs para el conteo automatizado y preciso de plantas de papa, utilizando imágenes capturadas por drones. Este enfoque busca optimizar la asignación de recursos, como fertilizantes y agua, reducir costos operativos y aumentar la competitividad del sector agrícola colombiano, contribuyendo así a mejorar la sostenibilidad y eficiencia en la producción de uno de los cultivos más importantes para la seguridad alimentaria del país.

IV. ESTADO DEL ARTE

El uso de CNNs ha transformado significativamente el monitoreo y el conteo de plantas en la agricultura, optimizando la gestión agronómica y promoviendo prácticas más eficientes. Cultivos de alta densidad, como la lechuga y la papa, se han beneficiado especialmente de soluciones basadas en aprendizaje profundo que permiten un conteo preciso de plantas, incluso en condiciones complejas. Este apartado revisa las investigaciones más recientes, incluyendo modelos avanzados como DA-ActNN-YOLOv5, LettuceNet y SRDPNet, con un enfoque particular en su potencial aplicación en los cultivos de papa en Colombia.

Tradicionalmente, el monitoreo agrícola se ha basado en métodos manuales o el uso de sensores, los cuales presentan limitaciones significativas, como errores humanos y baja escalabilidad. Los avances en CNNs, representados por arquitecturas como YOLOv5 y MobileNet, han proporcionado soluciones más precisas y escalables para abordar el conteo de plantas en campos densos [4], [5], [6]. Además, el uso de vehículos aéreos no tripulados (UAVs) ha facilitado el monitoreo en tiempo real, ofreciendo una visión integral del estado de los cultivos.

Entre los trabajos recientes, Dai et al. [4] presentaron DA-ActNN-YOLOv5, un modelo híbrido que combina YOLOv5 con técnicas avanzadas de aumentación de datos para mejorar la robustez en condiciones ambientales variables, como superposición y oclusión de plantas. Este modelo demostró ser útil en la agricultura de precisión al abordar desafíos en la detección de objetos en campos densos y en la estimación del rendimiento de cultivos. Por otro lado, Ruan et al. [7]

desarrollaron LettuceNet, un modelo diseñado para localizar y contar lechugas mediante un enfoque débilmente supervisado, reduciendo la dependencia del etiquetado manual, lo que a su vez disminuye los costos asociados al desarrollo de estas tecnologías. LettuceNet logró un error absoluto medio (MAE) de 2.4486 y un error cuadrático medio (RMSE) de 4.0247 en el conteo de lechugas.

Otra propuesta destacada es SRDPNet [8], desarrollada por Yang et al. (2023), que estima la densidad de plántulas de colza en condiciones de campo utilizando mecanismos de atención visual. Esta técnica mejora la precisión al enfocar en características clave, especialmente en escenarios donde la densidad de plántulas y la superposición de elementos representan desafíos significativos. De manera similar, Thakur et al. [9] implementaron redes neuronales profundas y UAVs para contar plantas en campos montañosos de la India, destacando el potencial de estas tecnologías en áreas de difícil acceso.

Los modelos revisados representan avances significativos en la automatización del conteo de plantas. Sin embargo, enfrentan limitaciones, como altos requisitos computacionales y dificultades de generalización a diferentes cultivos y condiciones ambientales. Aunque soluciones como DA-ActNN-YOLOv5, LettuceNet y SRDPNet han demostrado ser prometedoras para la agricultura de precisión, es necesario abordar estos desafíos para garantizar su aplicabilidad a gran escala y maximizar su impacto en la optimización de cultivos.

V. RECOLECCIÓN Y PREPARACIÓN DE DATOS

El conjunto de imágenes utilizado en este proyecto fue proporcionado por la empresa de tecnología agrícola Data-gricola.co S.A.S. Consiste en 73 fotografías aéreas capturadas el 29 de octubre de 2022, bajo condiciones de vuelo óptimas que incluyeron una visibilidad de 16 kilómetros, un índice geomagnético KP de 3.33, una temperatura ambiente de 10 °C y un 0% de probabilidad de precipitaciones. Las imágenes, almacenadas en formato PNG con una resolución de 4000x3000 píxeles, fueron obtenidas utilizando un dron DJI Mavic Air 2 equipado con una cámara FC3170. Las capturas se realizaron a una altitud de 100 metros sobre el nivel del suelo, a plena luz del día (8 a.m.), con una exposición de 2.97 EV y una apertura de f/2.8. La orientación de las imágenes fue 'superior izquierdo' (top-left), y se ajustaron según el índice de interoperabilidad R98, asegurando uniformidad y compatibilidad en plataformas de procesamiento.

El área capturada corresponde a terrenos agrícolas ubicados en el municipio de La Calera, Cundinamarca. Las imágenes abarcan dos cultivos de papa en fases fenológicas III y V, con coordenadas geográficas de 4°43'14.6"N 73°58'54.0"W, referenciadas bajo el Datum WGS 84 con el sistema de referencia espacial EPSG:4326.

Durante la preparación inicial de los datos, las imágenes originales fueron organizadas en una estructura lógica para facilitar su procesamiento. Se establecieron tres subdirectorios principales: raw, que contenía los datos originales sin procesar; images, donde se almacenaron las imágenes procesadas, recortadas y aumentadas; y labels, que albergó las anotaciones en formato YOLO. Esta organización optimizó el flujo de trabajo

en las etapas de etiquetado, entrenamiento y validación del modelo.

V-A. Procesamiento y anotación de las imágenes

El proceso de recorte de imágenes consistió en dividir las imágenes seleccionadas del conjunto original en segmentos más pequeños. De las 73 imágenes iniciales, se seleccionaron 29 siguiendo criterios de claridad, resolución y relevancia fenológica. Cada una de estas imágenes fue dividida en 24 segmentos de 640x640 píxeles, generando un total de 696 imágenes individuales listas para el etiquetado.

Posteriormente, los expertos seleccionaron 222 imágenes del conjunto inicial en las cuales identificaron y anotaron las clases correspondientes a las plantas de papa. Este proceso se llevó a cabo utilizando una herramienta gráfica personalizada para generar cajas delimitadoras, que marcaron con precisión las plantas presentes en cada imagen, siguiendo el formato YOLO. Sin embargo, durante el proceso de etiquetado, surgieron etiquetas con valores negativos debido a que algunos cuadros fueron etiquetados en un orden incorrecto, es decir, de derecha a izquierda y de abajo hacia arriba, en lugar del estándar de arriba hacia abajo y de izquierda a derecha.

Para evitar repetir este proceso, que es altamente demandante en tiempo y recursos, se decidió conservar estas etiquetas y corregirlas mediante un ajuste automatizado. Las etiquetas negativas fueron manipuladas y recalculadas a partir de sus valores originales para garantizar la coherencia. Este ajuste incluyó el cálculo correcto de los puntos de las cajas delimitadoras, asegurando que cumplieran con el formato requerido. Finalmente, se llevó a cabo una validación rigurosa para garantizar que las correcciones estuvieran alineadas con las imágenes, eliminando cualquier inconsistencia que pudiera afectar el rendimiento del modelo. Estas operaciones fueron facilitadas por la librería OpenCV [10], que proporcionó herramientas eficientes para la manipulación y el procesamiento de las etiquetas y las imágenes.

V-B. Aumentación de datos

Para mejorar la capacidad de generalización del modelo, se implementaron técnicas de aumentación de datos sobre las imágenes recortadas. Las transformaciones, aplicadas con las librerías Pillow [11] y Albumentations [12], incluyeron rotaciones, volteos horizontales y verticales, cambios de escala y ajustes en el brillo y contraste. Estas operaciones simulaban diferentes condiciones de captura, diversificando el conjunto de datos y aumentando la robustez del modelo frente a variaciones en el entorno. Las cajas delimitadoras se ajustaron automáticamente a los cambios realizados, asegurando la consistencia entre las imágenes y sus anotaciones.

El conjunto final de datos, compuesto por imágenes originales (iniciales), imágenes con etiquetas sin coordenadas negativas (útiles) e imágenes aumentadas (Aumentaciones), fue organizado en subconjuntos de entrenamiento, validación y prueba. Esta distribución permitió realizar un entrenamiento eficiente y evaluar el desempeño del modelo de manera objetiva, como se detalla en el cuadro I en la sección de resultados.

Cuadro I
DISTRIBUCIÓN DE IMÁGENES EN EL CONJUNTO DE DATOS

Dir	An/Al	Iniciales	Útiles	Aumentaciones
Test	640	23	10	158
Train	640	155	83	1100
Val	640	44	17	315

VI. MODELAMIENTO

Se implementó el modelo YOLO 11m, una variante diseñada para manejar imágenes con alta densidad de objetos, con el objetivo de lograr un equilibrio entre precisión y eficiencia en el procesamiento [14]. Inicialmente, se entrenó el modelo utilizando el conjunto de datos originales, del cual se excluyó el 55 % de las imágenes debido a la presencia de etiquetas con valores negativos. La distribución de los datos se estableció en proporciones de 70 % para entrenamiento, 20 % para validación y 10 % para prueba. En esta fase, la configuración inicial incluyó hiperparámetros como tamaños de lote (batch size) de 4 y 10, y un número de épocas (epochs) de 20, 40 y 50. Con estas configuraciones, el modelo logró un mAP50 de 32 % y un mAP50-95 de 12 %.

Dado que los resultados iniciales no alcanzaron los niveles deseados de precisión, se decidió refinar el modelo mediante la exploración de nuevas combinaciones de hiperparámetros. Para esta etapa, se consideraron tamaños de lote de 4, 8 y 16, épocas de 15, 20 y 25, y tasas de aprendizaje (learning rate) de 0.01 y 0.001. Debido a las limitaciones de recursos computacionales, se optó por realizar una búsqueda aleatoria restringida a tres combinaciones de hiperparámetros, lo que permitió identificar configuraciones más eficientes. Los valores usados se presentan en el cuadro II

Cuadro II
BUSQUEDA DE HIPERPARÁMETROS SIN AUMENTACIÓN

Epochs	Batch Size	Learning Rate
20	4	0.001
25	8	0.01
25	16	0.001

En una segunda etapa, se introdujeron datos aumentados para mejorar la capacidad de generalización del modelo. Las transformaciones aplicadas incluyeron rotaciones, volteos, y ajustes en brillo y contraste de las imágenes. El entrenamiento con datos aumentados utilizó configuraciones de hiperparámetros ajustadas, con tamaños de lote de 4, 10 y 60, épocas de 10, 50 y 100, y tasas de aprendizaje de 0.001, 0.01 y 0.1. Al igual que en la etapa anterior, se realizó una búsqueda aleatoria de hiperparámetros limitada a tres combinaciones.

Finalmente, el modelo optimizado alcanzó un valor de mAP (Mean Average Precision) del 51.5 %, evaluado en un rango de superposición IoU (Intersection over Union) entre 50 % y 95 %. Este resultado reflejó un rendimiento adecuado en la detección y localización de objetos específicos, confirmando la capacidad del modelo para manejar imágenes densas de cultivos de papa con precisión y eficiencia.

VII. RESULTADOS

Luego de realizar la búsqueda de hiperparámetros al conjunto de datos sin aumentaciones, los resultados de las tres iteraciones se presentan en el cuadro

Cuadro III
RESULTADOS MAP50-95. MODELO SIN AUMENTACIÓN

Epochs	Batch Size	Learning Rate	mAP50-95	Time (s)
20	4	0.01	0.10 %	163.649.147
25	8	0.01	0.10 %	2.867.138.262
25	16	0.001	0.11 %	4.255.336.621

Como se evidencia el mAP50-95 tiene mayor nivel en la iteración con una combinación de epoch de 25, batch de 16 y Learning rate de 0,001. La figura 1 muestra las métricas obtenidas con el modelo sin aumentación

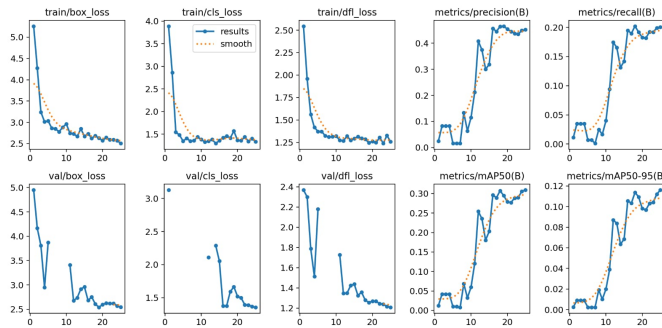


Figura 1. Métricas modelos sin aumentación

El análisis de las gráficas presentadas en la figura 1 evidencia un progreso constante en el entrenamiento del modelo YOLO, reflejado en la disminución de las pérdidas y la mejora gradual de las métricas clave. La pérdida de las cajas delimitadoras (box_loss) y la pérdida de clasificación (cls_loss) disminuyen de manera consistente, lo que indica que el modelo mejora tanto en la localización como en la clasificación de los objetos. Asimismo, la pérdida de distribución focalizada (dfl_loss) demuestra un ajuste progresivo, donde las cajas predichas se alinean cada vez más con los objetos reales. Las pérdidas observadas en el conjunto de validación siguen una tendencia similar a las de entrenamiento, lo que sugiere que el modelo está generalizando adecuadamente sin señales de sobreajuste.

En términos de métricas, el mAP50 (Mean Average Precision con $\text{IoU} \geq 50\%$) y el mAP50-95 (rango de IoU entre 50 % y 95 %) muestran mejoras significativas, alcanzando valores cercanos a 0.3 y 0.12, respectivamente, lo que refleja un aumento en la calidad de detección y localización de los objetos. La precisión aumenta progresivamente, alcanzando valores cercanos a 0.5, lo que indica que el modelo está reduciendo falsos positivos, mientras que el recall mejora de forma constante, llegando a 0.2, lo que evidencia una mayor detección de objetos presentes en las imágenes. Aunque las métricas indican un aprendizaje efectivo, el recall y el mAP50-95 tienen margen para mejorar, lo que podría lograrse con un mayor conjunto de datos, más iteraciones o ajustes en los hiperparámetros.

Posterior a esto, se obtuvieron los resultados para el modelo entrenado con aumentación de datos. Para este modelo la mejor combinación de hiperparámetros se presenta en el cuadro IV

Cuadro IV
RESULTADOS MAP50-95. MODELO CON AUMENTACIÓN

Epochs	Batch Size	Learning Rate	mAP50-95	Time (s)
50	6	0.01	0.16 %	2888
100	10	0.01	0.18 %	6202
50	6	0.01	0.16 %	3045

De acuerdo con lo presentado en la figura 2, el entrenamiento del modelo con datos aumentados mostró una mejora significativa, incrementando el mejor resultado obtenido por el modelo inicial en casi un 60 %, pasando de un mAP50-95 de 0.11 % a 0.18 %. Este avance resalta la importancia de disponer de un volumen amplio y diversificado de datos para abordar problemas complejos como el conteo de plantas en imágenes aéreas.

No obstante, cabe destacar que la búsqueda de hiperparámetros para optimizar el modelo resultó ser computacionalmente intensiva. El mejor modelo fue obtenido después de un tiempo de procesamiento total de 6,202 segundos (aproximadamente 1.7 horas) para explorar un máximo de tres iteraciones en un espacio de búsqueda de 27 combinaciones posibles. Este análisis se realizó utilizando un conjunto de 1,100 imágenes de entrenamiento, lo que subraya los desafíos asociados con la optimización de modelos en escenarios con recursos limitados.




Figura 2. Métricas modelos con aumentación

Tras completar la búsqueda de hiperparámetros y determinar el mejor modelo, se desarrolló una aplicación web interactiva soportada en Streamlit [13], disponible en el enlace <https://dl-grupo08-2024.streamlit.app/>. La aplicación permite a los usuarios cargar una imagen, configurar el umbral de confianza deseado para la detección, y procesar los resultados con un solo clic en el botón "Procesar", ver figura 3. Este enfoque simplifica la interacción con el modelo y lo hace accesible para usuarios con diferentes niveles de experiencia técnica.

La marca 1 en la figura 3, representa el puntaje de confianza que se desea para la identificación de plantas, y en la marca 2 se encuentra la opción para cargar nuevas imágenes.

Reconocimiento de imágenes de plantas de papa con YOLO

seleccione una imagen y presione el botón de 'Procesar' para detectar las plantas de papa

Seleccione el score mínimo de confianza para detección



Cargar imagen



Drag and drop file here

Limit 200MB per file • JPG, PNG, JPEG



Browse files

Figura 3. Interfaz inicial de la aplicación

Posterior a esto, la aplicación muestra dos columnas con los resultados de los dos modelos, ver figura 4. Cada columna tiene una imagen que indica el número de detecciones que cumplen con el umbral seleccionado en el paso uno.



Figura 4. Muestra de resultados desde la aplicación

En la figura 5 se muestra el número total de detecciones (número de plantas) que cumplen con ese umbral mínimo. En la parte inferior de la figura 5 se muestra el TOTAL de detecciones que tiene la imagen agrupada por intervalos de confianza, desde 0-10 % hasta 90 %-100 %.

El cierre de calles en las etapas fenológicas avanzadas del cultivo representa un desafío considerable tanto para expertos humanos como para el modelo, debido a la complejidad visual que implica la alta densidad del follaje. Aunque el modelo con datos aumentados mostró mejoras significativas en estas condiciones, persisten limitaciones en comparación con escenarios menos complejos. Estos resultados subrayan la importancia de iniciar estos procedimientos en fases fenológicas más tempranas, donde la estructura de las plantas permite una identificación más clara y precisa.

Esta herramienta resulta de gran utilidad para agricultores, empresarios y agremiaciones interesadas en el monitoreo de cultivos. A través de una interfaz sencilla e intuitiva, permite obtener una visión general de las plantas de papa detectadas en las imágenes, facilitando el análisis y la toma de decisiones basada en datos.

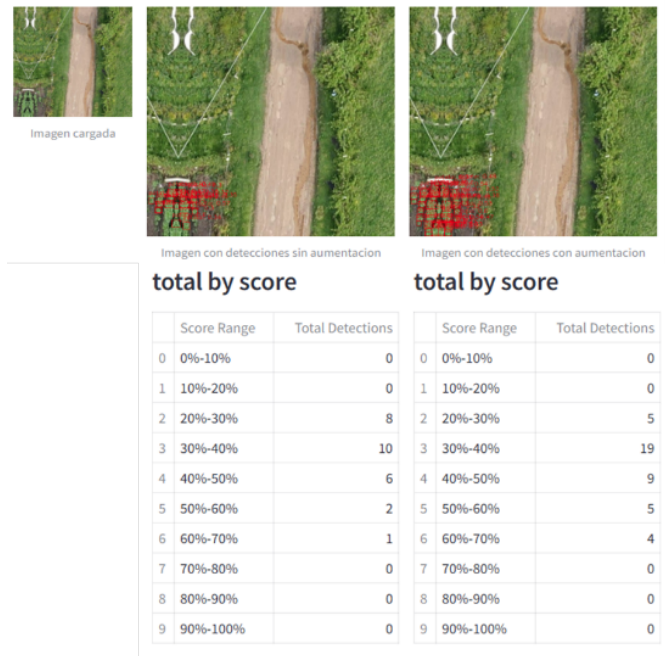


Figura 5. Intervalos de confianza en detección en plantas de papa

VIII. CONCLUSIONES

Este estudio demostró que los modelos basados en CNNs son herramientas eficaces para el conteo automatizado de cultivos de papa (*Solanum tuberosum*), incluso en condiciones desafiantes. En particular, se trabajó con imágenes capturadas durante el estado fenológico IV de la planta, una etapa en la que la alta densidad de follaje y el cierre de calles dificultan el análisis visual y automatizado. A pesar de estas condiciones, el modelo presentó un desempeño robusto, mostrando su capacidad para manejar escenarios complejos con alta densidad de clases por imagen.

La implementación de técnicas de aumentación de datos fue fundamental para mejorar el rendimiento del modelo, destacando la importancia de contar con datos de calidad y en cantidad suficiente durante el entrenamiento. Este enfoque no solo permitió superar limitaciones inherentes al conjunto de datos, sino que también facilitó la generalización del modelo en contextos variados.

Además, este trabajo subraya el potencial transformador del aprendizaje automático en la agricultura colombiana. La integración de tecnologías como drones y modelos de detección automatizada ofrece soluciones innovadoras que optimizan la gestión de cultivos, incrementan la sostenibilidad y la eficiencia en la producción agrícola, y sientan las bases para su aplicación en otros sectores del agro.

Sin embargo, este tipo de iniciativas enfrenta importantes retos que deben ser abordados para garantizar su escalabilidad y sostenibilidad. Entre ellos, se destaca la necesidad de desarrollar infraestructuras tecnológicas accesibles para pequeños y medianos agricultores, así como la optimización de los procesos de búsqueda de hiperparámetros, que suelen ser computacionalmente costosos. Además, es crucial fomentar la capacitación de los usuarios en el manejo de herramientas

digitales y promover la colaboración interdisciplinaria entre los sectores agrícola y tecnológico.

Finalmente, este proyecto demuestra que el uso de tecnologías avanzadas puede transformar prácticas agrícolas tradicionales, allanando el camino hacia un modelo agrícola más competitivo, inclusivo y resiliente en Colombia. A medida que se superen los desafíos tecnológicos y sociales, estas herramientas podrán consolidarse como elementos clave para la modernización del agro colombiano y la mejora de la seguridad alimentaria.

REFERENCIAS

- [1] Dejusticia, «Dejusticia», 28 Febrero 2023. [En línea]. Available: <https://www.dejusticia.org/la-radiografia-del-hambre-en-colombia-que-revelo-el-programa-mundial-de-alimentos/>. [Último acceso: 15 Septiembre 2024].
- [2] FAO, «Una guía sobre el Día Internacional de la Papa de 2024», FAO, Roma, Italia, 2024.
- [3] M. Medina, «Infobae», 2 Marzo 2023. [En línea]. Available: <https://www.infobae.com/colombia/2023/03/02/por-que-la-papa-esta-tan-cara-este-es-el-impresionante-aumento-en-su-costo-de-produccion-en-los-ultimos-anos-en-colombia/>. [Último acceso: 10 Septiembre 2024].
- [4] X. Dai, Z. Huang, Y. Fang y W. Lu, «DA-ActNN-YOLOv5: Hybrid Data Augmentation Model for Plant Detection in Agriculture», *Computational Intelligence and Neuroscience*, vol. 17, no. 4, pp. 1234–1245, 2022.
- [5] S. Ruan, X. Yang y Y. Hu, «LettuceNet: A Weakly-Supervised CNN Model for Lettuce Localization and Counting», *Agriculture*, vol. 14, no. 8, pp. 1–14, 2024.
- [6] J. Sharpe, A. Schumann, C. Yu y D. Boyd, «Vegetation detection and discrimination within vegetable plasticulture row-middles using a convolutional neural network», *Precision Agriculture*, vol. 21, pp. 987–1003, 2020.
- [7] S. Ruan, X. Yang y Y. Hu, «LettuceNet: A Novel Deep Learning Approach for Efficient Lettuce Localization and Counting», *Agriculture*, vol. 14, no. 8, pp. 1–14, 2024.
- [8] H. Yang, H. Yuan, Y. Wang y Z. Yin, «Rape seedling density estimation in-field conditions based on improved multi-column convolutional neural network», *Agronomy Journal*, pp. 810–826, 2023.
- [9] D. Thakur y S. Srinivasan, «AI-PUCMDL: artificial intelligence assisted plant counting through unmanned aerial vehicles in India's mountainous regions», *Environmental Monitoring and Assessment*, vol. 196, no. 406, 2024. [En línea]. Disponible: <https://doi.org/10.1007/s10661-024-12550-0>. [Accedido: 4-dic-2024].
- [10] G. Bradski, «The OpenCV Library», *Dr. Dobb's Journal of Software Tools*, 2000. [En línea]. Available: <https://opencv.org/>.
- [11] Pillow, «Pillow (PIL Fork)», [En línea]. Available: <https://python-pillow.org/>. [Último acceso: 30 Octubre 2024].
- [12] A. Buslaev, A. Parinov, E. Khvedchenya, V. I. Druzhkov, A. G. Savchenko y A. A. Kalinin, «Albumentations: Fast and Flexible Image Augmentations», *Information*, vol. 11, no. 2, pp. 1–31, 2020. [En línea]. Available: <https://albumentations.ai/>.
- [13] Streamlit, «Streamlit: The fastest way to build data apps», Streamlit Inc., 2024. [En línea]. Disponible: <https://streamlit.io/>. [Último acceso: 4 Diciembre 2024].
- [14] Ultralytics, «Ultralytics YOLO11», Ultralytics, 6 Noviembre 2024. [En línea]. Available: <https://docs.ultralytics.com/es/models/yolo11/#citations-and-acknowledgements>. [Último acceso: 15 Octubre 2024].